



---

# POLITECHNIKA POZNAŃSKA

---

WYDZIAŁ INFORMATYKI I TELEKOMUNIKACJI  
Instytut Informatyki

Praca dyplomowa magisterska

## ROZPOZNAWANIE EMOCJI W MEDIACH SPOŁECZNOŚCIOWYCH Z WYKORZYSTANIEM GŁĘBOKICH SIECI NEURONOWYCH

inż. Jakub Zdanowski, 127239

Promotor  
dr hab. inż. Agnieszka Ławrynowicz

Opiekun  
mgr inż. Maksymilian Marcinowski

POZNAŃ 2020

Tutaj będzie karta pracy dyplomowej;  
oryginał wstawiamy do wersji dla archiwum PP, w pozostałych kopiach wstawiamy ksero.

# Spis treści

<b>1</b>	<b>Wstęp</b>	<b>1</b>
1.1	Cel i zakres pracy . . . . .	1
1.2	Struktura pracy . . . . .	2
<b>2</b>	<b>Podstawy teoretyczne</b>	<b>3</b>
2.1	Rozpoznawanie emocji . . . . .	3
2.2	Modele emocji . . . . .	3
2.3	Głębokie uczenie . . . . .	4
<b>3</b>	<b>Analiza eksploracyjna</b>	<b>6</b>
3.1	Zbiór danych - EmoContext . . . . .	6
<b>4</b>	<b>Przetwarzanie danych</b>	<b>9</b>
4.1	Wczytanie i oczyszczenie danych . . . . .	9
4.2	Tokenizacja i wyrównanie . . . . .	9
4.3	Zagłębienia słów . . . . .	9
<b>5</b>	<b>Budowa modeli</b>	<b>11</b>
5.1	Jednowarstwowa architektura LSTM . . . . .	11
5.2	Głęboka architektura LSTM . . . . .	11
5.3	Głęboka architektura BERT . . . . .	11
5.4	Porównanie budowy modeli . . . . .	11
<b>6</b>	<b>Ewaluacja modeli</b>	<b>14</b>
6.1	Przebieg nauki . . . . .	14
6.2	Metryki . . . . .	14
6.3	Wyniki . . . . .	14
<b>7</b>	<b>Podsumowanie</b>	<b>16</b>
	<b>Literatura</b>	<b>17</b>

# Rozdział 1

## Wstęp

Emocje międzyludzkie są podstawą codziennych interakcji z innymi osobami, a badania naukowców pokazują, że emocje są zjawiskiem uniwersalnym dla ludzi bez względu na pochodzenie. Jednak wpływy kulturowe jak i interpersonalne odgrywają kluczową rolę w identyfikacji konkretnych nawet podstawowych emocji, takich jak radość, miłość, gniew, strach i złość. Im bardziej wyszczególnione są etykiety emocji, tym trudniej jest wykryć tę właściwą. System rozpoznawania emocji może okazać się przydatny do wzajemnego zrozumienia między osobami, poprzez dostarczenie niewykrytego sygnału emocji.

Doskonałym przykładem są emocje występujące w mediach społecznościowych, które w niektórych sytuacjach są bardzo wyraziste, lecz bywają też niejednoznaczne i przy tym mogą być wyrażane w wulgarny sposób. System wykrywania emocji w obszarze dialogów między ludźmi w postaci rozmowy na forum internetowym lub komentarzy pod postem może okazać się bardzo pomocny w poprawieniu bezpieczeństwa w Internecie dla ludzi młodych i dzieci. Przykładów zastosowań jest mnóstwo, kilka z nich to filtrowanie treści, blokada słów wulgarnych i obraźliwych oraz zdań z ukrytym podtekstem. Jest to także rekomendacja treści, grupowanie tekstu o podobnym znaczeniu, czy nawet badanie rynku. Można by wykorzystać taki system do zbadania większej liczby komentarzy, np. w przypadku koncernów samochodowych, czy firm produkujących elektronikę jakie emocje przewyższają w komentarzach pod wyświetlanymi reklamami w mediach społecznościowych. Czy jest to zachwyt, zadowolenie, czy rozczarowanie. Działania te mogły by odpowiedzieć na pytanie czy wydany właśnie przez nich produkt przyjmie się na rynku oraz co warto by poprawić. W takich przypadkach etykietowanie komentarzy przez człowieka mogłoby okazać się trudne do wykonania i niejednoznaczne oraz bardzo kosztowne i czasochłonne.

### 1.1 Cel i zakres pracy

Głównym celem pracy jest opracowanie modelu uczenia maszynowego opartego na głębokich sieciach neuronowych (klasyfikatora wieloklasowego) w celu detekcji emocji w tekście postów z dialogów z mediów społecznościowych. W ramach tego celu niezbędne będzie zapoznanie się z literaturą dotyczącą przetwarzania języka naturalnego i dostępnymi frameworkami do uczenia głębokiego, przeprowadzenie analizy eksploracyjnej wybranych zbiorów danych, wstępne przetworzenie tych danych po czym nastąpi budowa i ewaluacja kilku modeli o różnych architekturach w celu przeprowadzenia analizy porównawczej.

## 1.2 Struktura pracy

Struktura pracy jest następująca. Rozdział 2 przedstawia podstawy teoretyczne wymagane do zrozumienia dalszych etapów pracy wraz z przeglądem literatury. Rozdział 3 jest poświęcony analizie eksploracyjnej wybranych zbiorów danych. Rozdział 4 zawiera techniki przetwarzania wstępnego zbiorów danych. Rozdział 5 ukazuje budowę modeli a rozdział 6 ich ewaluację. Rozdział 7 zawiera podsumowanie pracy.

## Rozdział 2

# Podstawy teoretyczne

### 2.1 Rozpoznawanie emocji


Rozpoznawanie emocji w dialogach koncentruje się na wydobyciu emocji przekazanej w rozmowie pomiędzy co najmniej dwoma rozmówcami. Problem ten stawia bardzo dużo wyzwań, takich jak obecność sarkazmu w rozmowie, przesunięcie emocji do kolejnych wypowiedzi tego samego rozmówcy oraz uchwycenie szerszego kontekstu pomiędzy wypowiedziami różnych osób. Dużym plusem w tej dziedzinie jest bardzo dobra dostępność do danych, które pochodzą z platform społecznościowych takich jak Facebook, Youtube, Reddit, Twitter [7]. Poprzez łatwy dostęp do danych rozpoznawanie emocji w rozmowie staje się coraz bardziej popularne, a trudność tego problemu stwarza coraz to bardziej odległe granice co sprowadza się do wysokiego zainteresowania tą dziedziną przetwarzania języka naturalnego (ang. *natural language processing* - *NLP*).

Bardzo ważnym elementem w rozpoznawaniu emocji jest możliwość zrozumienia danego przekazu w kontekście, od którego może zależeć rodzaj emocji. Szczególnie trudnym przypadkiem jest zrozumienie i zapamiętanie kontekstu w konwersacji, co jak pokazują autorzy artykułu na temat architektury głębokiego uczenia do rozpoznawania emocji w rozmowach tekstowych [9], może okazać się kluczowym czynnikiem skuteczności rozpoznawania emocji. Do uzyskania satysfakcjonujących wyników nie wystarczają tradycyjne metody uczenia maszynowego lub najbardziej podstawowe architektury sieci neuronowych. Modele te wykorzystują zaawansowane techniki architektury transformera (ang. *the Transformer*) [8], które korzystają z podejścia mającego na celu poprawę modelowania sekwencji do sekwencji (ang. *Seq2Seq*) poprzez samoobserwację (ang. *self-attention*) i kodowanie pozycji (ang. *positional encoding*).

### 2.2 Modele emocji

Aby dobrze zrozumieć postawiony problem niezbędne będzie określenie czym są emocje. Wszyscy ludzie posiadają wrodzony zestaw podstawowych emocji, które można rozpoznać za pomocą gestów, czynów lub wypowiedzianych słów. Możemy wyróżnić dyskretne emocje, aby móc odróżnić je od siebie. Istnieje kilka definicji różnych modeli emocji, jednym z nich jest model zaproponowany przez Paula Ekmana [3]. Paul wraz ze współpracownikami stwierdzili, że istnieje sześć podstawowych emocji: gniew, obrzydzenie, strach, szczęście, smutek i zaskoczenie, a z każdą z tych emocji związane są jakieś cechy. Dzięki temu można wyrazić emocje w różnym stopniu a każda z nich jest zdefiniowana jako dyskretna kategoria, co pozwala na dość łatwą klasyfikację konkretnej emocji.

Kolejną definicję modelu emocji przedstawił Robert Plutchik, który podzielił emocje na osiem podstawowych typów, z których każdy ma drobniejsze podtypy pokrewne [6], zaprezentowane na rysunku 2.1 za pomocą koła emocji. Prezentuje on emocje jako koncentryczne kręgi, gdzie we-




**Rysunek 2.1.** Koło emocji Plutchika [6].

wewnętrzne części odpowiadają za podstawowe emocje a te zewnętrzne za bardziej złożone. Model ten jest dyskretny, lecz widać w nim pewne zależności i podobieństwa pomiędzy sąsiadującymi częściami koła emocji. Budowa ta wynika ze złożoności emocji i możliwości wyrażania ich intensywności.

Podsumowując wymienione modele emocji możemy wydzielić dwa główne typy: kategoriowe oraz wymiarowe. Modele wymiarowe mapują emocję w sposób ciągły na wektory. Modele kategoriowe klasyfikują emocję do konkretnej emocji dyskretnej, np. jednej z wybranego modelu emocji Ekmana lub Plutchika. Modele kategoriowe mają pewne wady. Jedną z nich jest brak możliwości opisanie innych emocji oraz utrudnione opisywanie emocji złożonej z kilku różnych podtypów zdefiniowanych w dyskretnym modelu. Drugą wadą jest brak możliwości porównywania emocji, co umożliwiłby model wymiarowy, za pomocą porównywania dwóch wektorów. Wybór odpowiedniego modelu emocji nie jest łatwy, a jednocześnie jest bardzo ważnym elementem do późniejszej klasyfikacji emocji. Decydując się na kategoriowy typ emocji, z jednej strony mamy prosty model Ekmana który nie jest w stanie zamodelować złożonych emocji. Z drugiej strony w modelu Plutchika może być bardzo trudno rozróżnić drobnoziarniste emocje od siebie. Wybór ten należy zatem dokonać mając na uwadze wielkość oraz jakość zbioru danych.

## 2.3 Głębokie uczenie

W przetwarzaniu języka naturalnego z użyciem głębokich sieci neuronowych coraz częściej używane są techniki transferu wiedzy (ang. *transfer learning*) oraz adaptacji domenowej. Model języka jest kluczowym elementem do zastosowania powyższych technik. Umożliwia on przewidzenie kontekstu w jakim dane słowo znajduje się w zdaniu i na tej podstawie umożliwia odkryć jego prawdziwy sens. Jest uważany za bardzo istotny element w dziedzinie *NLP*, który stanowi



**Rysunek 2.2.** 3 etapy nauki modelu języka (ang. *LM*) w metodzie ULMFIT [4].

podstawę do wszelkich zastosowań przetwarzania języka naturalnego. Najważniejsze jego cechy to zrozumienie długofalowych zależności i hierarchicznej struktury tekstu, a największe zalety to otwarte i wolne zasoby do jego stworzenia. Jest tworzony za pomocą nienadzorowanego procesu uczenia, który potrzebuje tylko korpusu nieoznakowanego tekstu.

Znakomitym przykładem użycia transferu wiedzy za pomocą wielokrotnego uczenia modelu języka jest metoda *ULMFIT* [4] (ang. *Universal Language Model Fine-tuning for Text Classification*), która może być zastosowana do każdego zadania w NLP. Zastosowane są w niej techniki, które są kluczowe dla dostrojenia modelu językowego. Używane są w niej 3 warstwy sieci neuronowej wykorzystującej komórki LSTM (ang. *Long Short-Term Memory*), które w przeciwieństwie do standardowych komórek sieci neuronowych, posiadają połączenia zwrotne, umożliwiające zapamiętanie sąsiednich stanów w sieci. Dodatkowo zastosowana jest technika przerywania (ang. *dropout*) niwelująca problem przeuczenia. Cały etap nauki w metodzie *ULMFIT* składa się z 3 etapów zaprezentowanych na rysunku 2.2. Na początku następuje szkolenie wstępne modelu językowego na dowolnym korpusie, następnie dostrojenie modelu językowego na zadaniu docelowym i na końcu dostrojenie klasyfikatora na zadaniu docelowym. Dzięki zastosowaniu tych technik możliwe jest wyuczenie wstępne modelu języka na dowolnych danych, (np. korpus Wikipedii) a następnie wykorzystanie tego wstępnie wyuczonego modelu na zadaniu docelowym. Na podobnej zasadzie działają dzisiejsze najbardziej wyrafinowane architektury głębokich sieci neuronowych w zastosowaniu przetwarzania języka naturalnego nazywane aktualnym stanem techniki (ang. *state of the art*).



## Rozdział 3

# Analiza eksploracyjna

### 3.1 Zbiór danych - EmoContext

Zbiór danych został udostępniony przez zespół z Międzynarodowych Warsztatów Ewaluacji Semantycznej (ang. *SemEval-2019 International Workshop on Semantic Evaluation*) jako jedno z zadań konkursowych o nazwie EmoContext<sup>1</sup> (ang. *Contextual Emotion Detection in Text*). Celem jest odkrycie prawidłowej etykiety emocji dla danego dialogu, składającego się z trzech wypowiedzi. W zadaniu tym użyty jest uproszczony model emocji zaproponowany przez Paula Ekmana [3], składający się z czterech klas: *Happy*, *Sad*, *Angry* oraz *Others*. Przykładowe dialogi oraz odpowiadające im etykiety emocji pochodzące ze zbioru treningowego zaprezentowane są na rysunku 3.1.

	id	turn1	turn2	turn3	label
0	0	Don't worry I'm girl	hmm how do I know if you are	What's ur name?	others
1	1	When did I?	saw many times i think -_-	No. I never saw you	angry
2	2	By	by Google Chrome	Where you live	others
3	3	U r ridiculous	I might be ridiculous but I am telling the truth.	U little disgusting whore	angry
4	4	Just for time pass	wt do u do 4 a living then	Maybe	others
5	5	I'm a dog person	youre so rude	Whaaaaat why	others
6	6	So whatsup	Nothing much. Sitting sipping and watching TV....	What are you watching on tv?	others
7	7	Ok	ok im back!!	So, how are u	others
8	8	Really?	really really really really really	Y saying so many times...i can hear you	others
9	9	Bay	in the bay	👉 love you	others

Rysunek 3.1. Przykładowe dialogi w danych z EmoContext wraz z etykietą emocji.

Przez organizatorów konkursu udostępnione zostały następujące zbiory do ewaluacji własnych modeli: zbiór treningowy (*train*), zbiór walidacyjny (*dev*) oraz zbiór testowy (*test*). Każdy z tych zbiorów zawiera tę samą strukturę danych, każdy przykład składa się z identyfikatora (*Id*), trzech wypowiedzi w dialogu oraz etykiety emocji. Szczegółowe informacje na temat tych zbiorów ukazuje tabela 3.1.


Aby lepiej zrozumieć dane treningowe przeprowadzone zostały podstawowe analizy eksploracyjne tego zbioru. Jedną z nich jest rozkład długości całego dialogu zaprezentowany na rysunku 3.2. Widzimy na nim że przeważające dialogi są dosyć krótkie, średnio 62 znaki, co może utrudnić zadanie rozpoznania właściwej emocji. Zauważyć można także występujący długi ogon w kierunku coraz dłuższych dialogów, najdłuższy z nich ma 692 znaki.

<sup>1</sup><https://www.humanizing-ai.com/emocontext.html>


Tablica 3.1

Tabela prezentująca informacje o zbiorach w danych z EmoContext.

zbiór	liczba przykładów	najczęstsza klasa
train	30160	<i>Others</i> 50%
dev	2755	<i>Others</i> 84%
test	5509	<i>Others</i> 84%




Rysunek 3.2. Rozkład długości dialogu w danych z EmoContext.




Rysunek 3.3. Niezbalansowany rozkład etykiet emocji w danych z EmoContext.

Kolejna analiza to histogram częstości występowania danej etykiety w zbiorze treningowym, dzięki temu można sprawdzić czy występuje niezbalansowanie klas. Rysunek 3.3 prezentuje dominację klasy *Others* nad pozostałymi klasami, jest średnio ponad dwukrotnie liczniejszy od każdej z pozostałych etykiet.


Ostatnim elementem analizy eksploracyjnej tego zbioru jest identyfikacja najczęściej występujących *N-gramów*, gdzie *N* to liczba zlepek słów występujących obok siebie w dialogach. Rysunki 3.4, 3.5 oraz 3.6 ukazują histogramy najczęstszych *N-gramów*. Można zauważyć że najczęściej występującymi słowami są słowa należące do grupy słów nie wnoszących znaczenia (ang. *stop words*), np.: słowa popularne, spójniki, przedimki, jednak często występujące słowa to także wnoszące dużo znaczenia do wypowiedzi takie jak *love*, *like*, *good*, *hate*.



**Rysunek 3.4.** Rozkład wystąpień najczęstszych 1-gramów (wyrazów) w danych z EmoContext.



**Rysunek 3.5.** Rozkład wystąpień najczęstszych 2-gramów w danych z EmoContext.



**Rysunek 3.6.** Rozkład wystąpień najczęstszych 3-gramów w danych z EmoContext.

## Rozdział 4

# Przetwarzanie danych

### 4.1 Wczytanie i oczyszczenie danych

Pierwszym etapem przygotowania danych do użycia w modelu jest ich wczytanie oraz przetworzenie. Zbiór danych z EmoContext zawiera pięć kolumn (rys. 3.1). W pierwszej kolumnie znajduje się identyfikator, w kolumnach od 2 do 4 zawarty jest docelowy tekst który będzie użyty jako wejście do modelu, a w ostatniej kolumnie znajduje się etykieta emocji. Po wczytaniu danych następuje połączenie trzech kolumn z tekstem w jeden ciąg znaków, oddzielone znakiem specjalnym *EOS* (ang. *end of sentence*). Jest to niezbędna operacja która umożliwi docelowemu modelowi oddzielić trzy wypowiedzi od siebie. Następnie na tak otrzymanym ciągu znaków wykonywane są operacje usuwania powtarzających się znaków interpunkcyjnych (np. *"!!!!"* zostanie zamienione na pojedynczy znak *"!"*). Na końcu wykonywane jest oddzielenie znaków interpunkcyjnych od wyrazów, usunięcie powtarzających się spacji oraz zamiana wszystkich dużych liter na małe.


### 4.2 Tokenizacja i wyrównanie

Modele głębokie przetwarzania języka naturalnego nie operują na jawnym tekście w postaci ciągu znaków, tylko na reprezentacji w postaci liczbowej. Do reprezentacji wyrazów używane są słowniki które przechowują wszystkie znane słowa z korpusu uczącego. Do tej zamiany użyta została metoda *Tokenizer* z pakietu TensorFlow. Klasa ta pozwala na wektoryzację korpusu tekstu, poprzez przekształcenie każdego wyrazu w liczbę całkowitą. Każda z tych liczb odpowiada indeksowi tego słowa w słowniku.

Po przekształceniu każdego słowa w token następuje wyrównanie długości wszystkich przykładów w zbiorze. Przykładowa liczba użyta do wyrównania (ang. *padding*) to 20. Wszystkie przykłady, które mają mniejszą liczbę tokenów, wypełniane są tokenem zerowym aż do osiągnięcia długości 20, a wszystkie przykłady które mają większą liczbę tokenów są skracane od końca. W ten sposób została utworzona macierz danych która może być wykorzystana do użycia w nauce i ewaluacji modeli.

### 4.3 Zagłębienia słów

W przypadku głębokich sieci neuronowych z rekurencyjnymi komórkami LSTM wysoce efektywne jest użycie zagłębień słów (ang. *words embeddings*) jako wejścia do pierwszej warstwy sieci neuronowej. Osadzanie słów jest przeprowadzone za pomocą mapowania tych słów na wektory liczb rzeczywistych. Reprezentacja słów jako wektory liczb jest rozszerzeniem reprezentacji *jeden z  $N$*  (ang. *one hot encodings*), która jest używana w celu zwiększenia wydajności modeli NLP.



Rysunek 4.1. Przykładowe słowa w przestrzeni wektorowej GloVe [1].

Jest to także możliwość użycia transferu wiedzy w postaci wstępnie wytrenowanych zagłębień słów jako reprezentacji danych wejściowych. Jednym z algorytmów, który umożliwia stworzenie takiej reprezentacji jest metoda GloVe [1] (ang. *Global Vectors for Word Representation*), stworzona przez zespół z Uniwersytetu Stanford. Udostępniona przez nich macierz umożliwia użycie tej reprezentacji, jako odwzorowanie słów na wektory liczb rzeczywistych. Słowa zmapowane w tej przestrzeni mają zachowane pewne właściwości, odległość między nimi jest powiązana z podobieństwem semantycznym. Na rysunku 4.1 ukazane są przykładowe słowa i zachowane podobieństwo np. między słowami *love* i *beautiful*. Sposób uzyskania tej reprezentacji bazuje na współwystępowaniu danych słów w korpusie w otoczeniu które je definiuje. Główną intuicją tego modelu jest założenie, że proporcje prawdopodobieństwa współwystępowania słów mają potencjał do kodowania jakiejś formy znaczenia. Wynikiem tej metody są wektory słów które bardzo dobrze radzą sobie z zadaniami opartymi o podobieństwo, analogię, a także odkrywaniu semantyki emocjonalnej słów i wiele innych wymienionych w pakiecie *word2vec* [5].

## Rozdział 5

# Budowa modeli

### 5.1 Jednowarstwowa architektura LSTM

5.1 rysunek przedstawiający budowę jednowarstwowej architektury LSTM.

5.2 tabela przedstawiająca szczegóły budowy jednowarstwowej architektury LSTM.

### 5.2 Głęboka architektura LSTM

5.3 graf głębokiej architektury LSTM

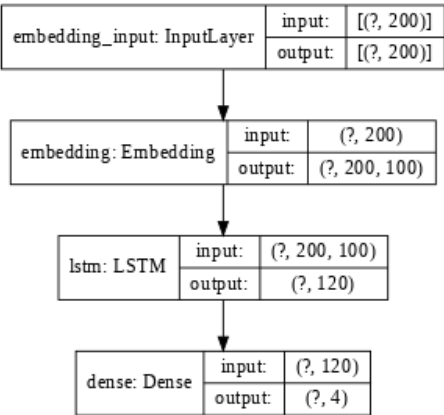
5.4 tabela przedstawiająca szczegóły budowy głębokiej architektury LSTM.

[1] GLOVE

### 5.3 Głęboka architektura BERT

[2] BERT

### 5.4 Porównanie budowy modeli

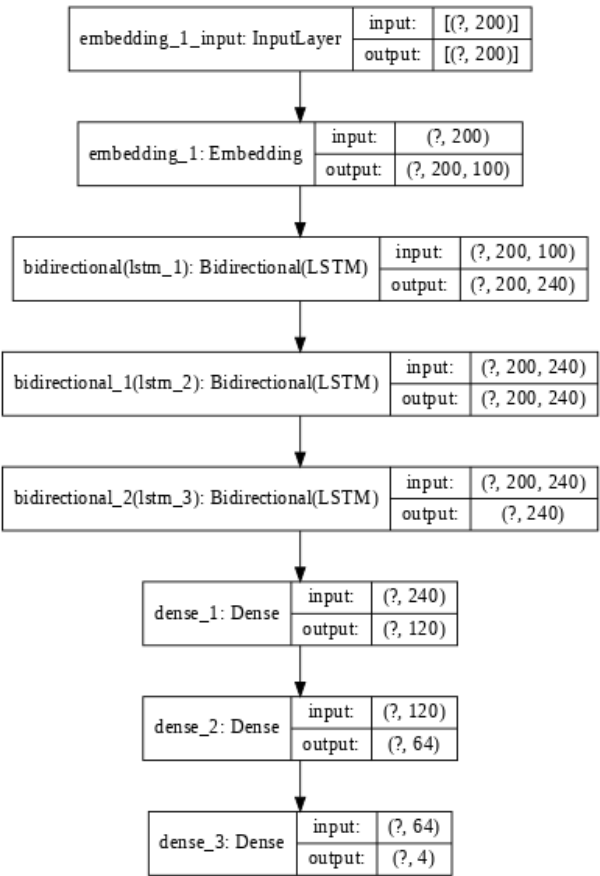


Rysunek 5.1. Graf przedstawiający budowę jednowarstwowej architektury LSTM.

Model: "Jednowarstwowa architektura LSTM"		
Layer (type)	Output Shape	Param #
embedding (Embedding)	(None, 200, 100)	1683200
lstm (LSTM)	(None, 120)	106080
dense (Dense)	(None, 4)	484
Total params: 1,789,764		
Trainable params: 106,564		
Non-trainable params: 1,683,200		

Rysunek 5.2. Tabela przedstawiająca szczegóły budowy jednowarstwowej architektury LSTM.

Tablica 5.1			
Tabela porównująca szczegóły budowy poszczególnych model.			
model	parametry trenowalne	parametry stałe	SUMA
Jednowarstwowy LSTM	106,564	1,683,200	1,789,764
Głęboki LSTM	942,204	1,683,200	2,625,404
BERT todo	xx	xx	xxx



Rysunek 5.3. Graf przedstawiający budowę głębokiej architektury LSTM.

Model: "Głęboka architektura LSTM"		
Layer (type)	Output Shape	Param #
embedding_1 (Embedding)	(None, 200, 100)	1683200
bidirectional (Bidirectional)	(None, 200, 240)	212160
bidirectional_1 (Bidirectional)	(None, 200, 240)	346560
bidirectional_2 (Bidirectional)	(None, 240)	346560
dense_1 (Dense)	(None, 120)	28920
dense_2 (Dense)	(None, 64)	7744
dense_3 (Dense)	(None, 4)	260
Total params: 2,625,404		
Trainable params: 942,204		
Non-trainable params: 1,683,200		

Rysunek 5.4. Tabela przedstawiająca szczegóły budowy głębokiej architektury LSTM.



## Rozdział 6

# Ewaluacja modeli

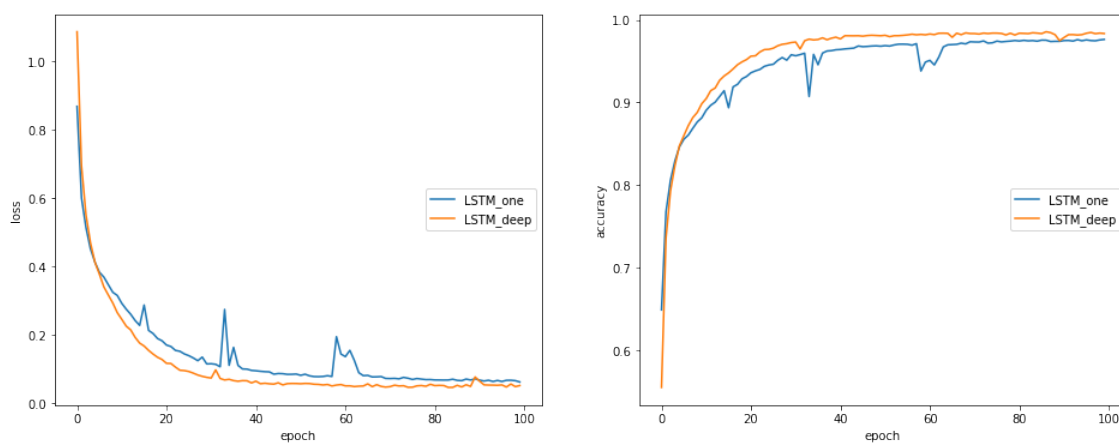
### 6.1 Przebieg nauki

6.1 tabela przedstawiająca szczegóły budowy głębokiej architektury LSTM.

### 6.2 Metryki

TODO

### 6.3 Wyniki



**Rysunek 6.1.** Wykresy przedstawiające przebieg nauki dla modeli jednowarstwowego LSTM oraz głębokiego LSTM

**Tablica 6.1**  
Tabela pokazująca wyniki poszczególnych modeli.

model	dokładność	mikro precyzja	micro czułość	mikro F1
Jednowarstwowy LSTM	0.85	0.49	0.70	0.58
Głęboki LSTM	0.87	0.51	0.71	0.60
BERT todo	xx	xx	xxx	xxx

## Rozdział 7

# Podsumowanie

Zakończenie pracy zwane również Uwagami końcowymi lub Podsumowaniem powinno zawierać ustosunkowanie się autora do zadań wskazanych we wstępie do pracy, a w szczególności do celu i zakresu pracy oraz porównanie ich z faktycznymi wynikami pracy. Podejście takie umożliwia jasne określenie stopnia realizacji założonych celów oraz zwrócenie uwagi na wyniki osiągnięte przez autora w ramach jego samodzielnej pracy.

Integralną częścią pracy są również dodatki, aneksy i załączniki zawierające stworzone w ramach pracy programy, aplikacje i projekty.

# Literatura

- [1] Robin Brochier, Adrien Guille, and Julien Velcin. Global vectors for node representations, 2019.
- [2] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding, 2018.
- [3] Paul Ekman. Facial expression and emotion, 1993.
- [4] Jeremy Howard and Sebastian Ruder. Universal language model fine-tuning for text classification, 2018.
- [5] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space, 2013.
- [6] Robert Plutchik. A psychoevolutionary theory of emotions, 1982.
- [7] Soujanya Poria, Navonil Majumder, Rada Mihalcea, and Eduard Hovy. Emotion recognition in conversation: Research challenges, datasets, and recent advances, 2019.
- [8] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2017.
- [9] Peixiang Zhong, Di Wang, and Chunyan Miao. Knowledge-enriched transformer for emotion detection in textual conversations, 2019.



© 2020 inż. Jakub Zdanowski

Instytut Informatyki, Wydział Informatyki i Telekomunikacji  
Politechnika Poznańska

Skład przy użyciu systemu  $\text{\LaTeX}$  na platformie Overleaf.