



POLITECHNIKA POZNAŃSKA

WYDZIAŁ INFORMATYKI I TELEKOMUNIKACJI
Instytut Informatyki

Praca dyplomowa magisterska

**ROZPOZNAWANIE EMOCJI W MEDIACH
SPOŁECZNOŚCIOWYCH Z WYKORZYSTANIEM GŁĘBOKICH
SIECI NEURONOWYCH**

inż. Jakub Zdanowski, 127239

Promotor
dr hab. inż. Agnieszka Ławrynowicz

Opiekun
mgr inż. Maksymilian Marcinowski

POZNAŃ 2020

Tutaj będzie karta pracy dyplomowej;
oryginał wstawiamy do wersji dla archiwum PP, w pozostałych kopiach wstawiamy ksero.

Spis treści

1	Wstęp	1
1.1	Cel i zakres pracy	1
1.2	Struktura pracy	2
2	Podstawy teoretyczne	3
2.1	Rozpoznawanie emocji	3
2.2	Modele emocji	3
3	Analiza eksploracyjna	5
3.1	Zbiór danych - EmoContext, SEMEVAL 2019	5
4	Przetwarzanie danych	8
5	Budowa modeli	9
6	Ewaluacja modeli	10
7	Podsumowanie	11
	Literatura	12

Rozdział 1

Wstęp

Emocje międzyludzkie są podstawą codziennych interakcji z innymi osobami, a badania naukowców pokazują że emocje są zjawiskiem uniwersalnym dla ludzi bez względu na pochodzenie. Jednak wpływy kulturowe jak i interpersonalne odgrywają kluczową rolę w identyfikacji konkretnych nawet podstawowych emocji, takich jak radość, miłość czy strach i złość. Im bardziej wyszczególnione są etykiety emocji tym trudniej jest wykryć tę właściwą. System rozpoznawania emocji może okazać się przydatny do wzajemnego zrozumienia między osobami poprzez dostarczenie niewykrytego sygnału emocji.

Doskonałym przykładem są emocje występujące w mediach społecznościowych, które w niektórych sytuacjach są bardzo wyraziste lecz w niektórych niejednoznaczne i przy tym wulgarne. System wykrywania emocji w obszarze dialogów między ludźmi w postaci rozmowy na forum internetowym lub komentarzy pod postem może okazać się bardzo pomocny w poprawieniu bezpieczeństwa w Internecie dla ludzi młodych i dzieci. Przykładów zastosowań jest mnóstwo, kilka z nich to filtrowanie treści, blokada słów wulgaryzmów i obraźliwych oraz zdań z ukrytym podtekstem, jest to także rekomendacja treści, grupowanie tekstu o podobnym znaczeniu, czy nawet badanie rynku. Można by wykorzystać taki system do zbadania większej liczby komentarzy, np. w przypadku koncernów samochodowych czy firm produkujących elektronikę jakie emocje przeżywają w komentarzach pod wyświetlanymi reklamami w mediach społecznościowych, czy jest to zachwyt, zadowolenie, czy rozczarowanie. Działania te mogłyby odpowiedzieć na pytanie czy wydany właśnie przez nich produkt przyjmie się na rynku oraz co warto by poprawić. W takich przypadkach etykietowanie komentarzy przez człowieka mogłoby okazać się trudne do wykonania i niejednoznaczne oraz bardzo kosztowne oraz czasochłonne.

1.1 Cel i zakres pracy

Głównym celem pracy jest opracowanie modelu uczenia maszynowego opartego na głębokich sieciach neuronowych (klasyfikatora wieloklasowego) w celu detekcji emocji w tekście postów z dialogów z mediów społecznościowych. W ramach tego celu niezbędne będzie zapoznanie się z literaturą dotyczącą przetwarzania języka naturalnego i dostępnymi frameworkami do uczenia głębokiego, przeprowadzenie analizy eksploracyjnej wybranych zbiorów danych, wstępne przetworzenie tych danych po czym nastąpi budowa i ewaluacja kilku modeli o różnych architekturach w celu przeprowadzenia analizy porównawczej.

1.2 Struktura pracy

Struktura pracy jest następująca. Rozdział 2 przedstawia podstawy teoretyczne wymagane do zrozumienia dalszych etapów pracy wraz z przeglądem literatury. Rozdział 3 jest poświęcony analizie eksploracyjnej wybranych zbiorów danych. Rozdział 4 zawiera techniki przetwarzania wstępnego zbiorów danych. Rozdział 5 ukazuje budowę modeli a rozdział 6 ich ewaluację. Rozdział 7 zawiera podsumowanie pracy.

Rozdział 2

Podstawy teoretyczne

2.1 Rozpoznawanie emocji

Rozpoznawanie emocji w dialogach koncentruje się na wydobyciu emocji przekazanej w rozmowie pomiędzy co najmniej dwoma rozmówcami. Problem ten stawia bardzo dużo wyzwań, takich jak obecność sarkazmu w rozmowie, przesunięcie emocji do kolejnych wypowiedzi tego samego rozmówcy oraz uchwycenie szerszego kontekstu pomiędzy wypowiedziami różnych rozmówców. Dużym plusem w tej dziedzinie jest bardzo dobra dostępność do danych, które pochodzą z platform społecznościowych takich jak Facebook, Youtube, Reddit, Twitter [6]. Poprzez łatwą dostępność do danych rozpoznawanie emocji w rozmowie staje się coraz bardziej popularne, a trudność tego problemu stwarza coraz to bardziej odległe granice co sprowadza się do wysokiego zainteresowania tą dziedziną przetwarzania języka naturalnego (ang. *natural language processing*).

Bardzo ważnym elementem w rozpoznawaniu emocji jest możliwość zrozumienia danego przekazu w kontekście, od którego może zależeć rodzaj emocji. Szczególnie trudnym przypadkiem jest zrozumienie i zapamiętanie kontekstu w konwersacji, co jak pokazuje [8], może okazać się kluczowym czynnikiem skuteczności rozpoznawania emocji. Do uzyskania satysfakcjonujących wyników nie wystarczają tradycyjne metody uczenia maszynowego lub najbardziej podstawowe architektury sieci neuronowych. Modele te wykorzystują zaawansowane techniki architektury transformera (ang. *the Transformer*) [7] które korzystają z podejścia mającego na celu poprawę modelowania sekwencji do sekwencji (ang. *Seq2Seq*) poprzez samoobserwację (ang. *self-attention*) i kodowanie pozycji (ang. *positional encoding*).

2.2 Modele emocji

Aby dobrze zrozumieć postawiony problem niezbędne będzie określenie czym są emocje. Wszyscy ludzie posiadają wrodzony zestaw podstawowych emocji, które można rozpoznać za pomocą gestów, czynów lub wypowiedzianych słów. Możemy wyróżnić dyskretne emocje aby móc odróżnić je od siebie. Istnieje kilka definicji różnych modeli emocji, jednym z nich jest model zaproponowany przez Paula Ekmana [3]. Paul wraz ze współpracownikami stwierdzili, że istnieje sześć podstawowych emocji: gniew, obrzydzenie, strach, szczęście, smutek i zaskoczenie, a z każdą z tych emocji związane są jakieś cechy. Dzięki temu można wyrazić emocje w różnym stopniu a każda z nich jest zdefiniowana jako dyskretna kategoria co pozwala na dość łatwą klasyfikację konkretnej emocji.

Kolejną definicję modelu emocji przedstawił Robert Plutchik, który podzielił emocje na osiem podstawowych typów, z których każdy ma drobniejsze podtypy pokrewne [5], zaprezentowane na rysunku 2.1 za pomocą koła emocji. Reprezentuje on emocje jako koncentryczne kręgi, wewnętrzne części odpowiadają za podstawowe emocje a te zewnętrzne za bardziej złożone. Model ten jest

Rozdział 3

Analiza eksploracyjna

3.1 Zbiór danych - EmoContext, SEMEVAL 2019

Zbiór danych został udostępniony przez zespół z Międzynarodowych Warsztatów Ewaluacji Semantycznej (ang. *SemEval-2019 International Workshop on Semantic Evaluation*) jako jedno z zadań konkursowych o nazwie EmoContext¹ (ang. *Contextual Emotion Detection in Text*). Celem jest odkrycie prawidłowej etykiety emocji dla danego dialogu, składającego się z trzech wypowiedzi. W zadaniu tym użyty jest uproszczony model emocji zaproponowany przez Paula Ekmana [3], składający się z czterech klas: *Happy*, *Sad*, *Angry* oraz *Others*. Przykładowe dialogi oraz odpowiadające im etykiety emocji pochodzące ze zbioru treningowego zaprezentowane są na rysunku 3.1.

	id	turn1	turn2	turn3	label
0	0	Don't worry I'm girl	hmm how do I know if you are	What's ur name?	others
1	1	When did I?	saw many times i think --	No. I never saw you	angry
2	2	By	by Google Chrome	Where you live	others
3	3	U r ridiculous	I might be ridiculous but I am telling the truth.	U little disgusting whore	angry
4	4	Just for time pass	wt do u do 4 a living then	Maybe	others
5	5	I'm a dog person	youre so rude	Whaaaaat why	others
6	6	So whatsup	Nothing much. Sitting sipping and watching TV....	What are you watching on tv?	others
7	7	Ok	ok im back!!	So, how are u	others
8	8	Really?	really really really really really	Y saying so many times...i can hear you	others
9	9	Bay	in the bay	👉 love you	others

Rysunek 3.1. Przykładowe dialogi w danych z EmoContext wraz z etykietą emocji.

Przez organizatorów konkursu udostępnione zostały następujące zbiory do ewaluacji własnych modeli: zbiór treningowy (*train*), zbiór walidacyjny (*dev*) oraz zbiór testowy (*test*). Każdy z tych zbiorów zawiera tę samą strukturę danych, każdy przykład składa się z identyfikatora (*Id*), trzech wypowiedzi w dialogu oraz etykiety emocji. Szczegółowe informacje na temat tych zbiorów ukazuje tabela 3.1.

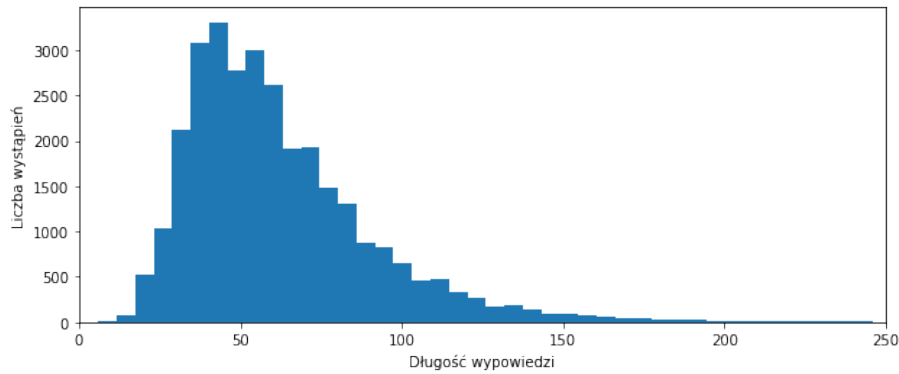
Aby lepiej zrozumieć dane treningowe przeprowadzone zostały podstawowe analizy eksploracyjne tego zbioru. Jedną z nich jest rozkład długości całego dialogu zaprezentowany na rysunku 3.2. Widzimy na nim że przeważające dialogi są dosyć krótkie, średnio 62 znaki, co może utrudnić zadanie rozpoznania właściwej emocji. Zauważyć można także występujący długi ogon w kierunku coraz dłuższych dialogów, najdłuższy z nich ma 692 znaki.

¹<https://www.humanizing-ai.com/emocontext.html>

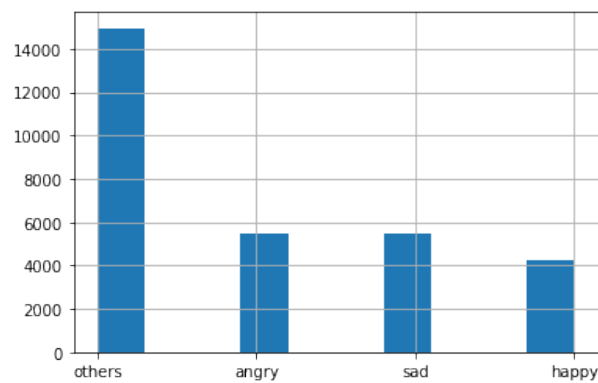
Tablica 3.1

Tabela prezentująca informacje o zbiorach w danych z EmoContext.

zbiór	liczba przykładów	najczęstsza klasa
train	30160	<i>Others</i> 50%
dev	2755	<i>Others</i> 84%
test	5509	<i>Others</i> 84%




Rysunek 3.2. Rozkład długości dialogu w danych z EmoContext.




Rysunek 3.3. Niezbalansowany rozkład etykiet emocji w danych z EmoContext.

Kolejna analiza to histogram częstości występowania danej etykiety w zbiorze treningowym, dzięki temu można sprawdzić czy występuje niezbalansowanie klas. Rysunek 3.3 prezentuje dominację klasy *Others* nad pozostałymi klasami, jest średnio ponad dwukrotnie liczniejszy od każdej z pozostałych etykiet.


Ostatnim elementem analizy eksploracyjnej tego zbioru jest identyfikacja najczęściej występujących *N-gramów*, gdzie *N* to liczba zlepek słów występujących obok siebie w dialogach. Rysunki 3.4, 3.5 oraz 3.6 ukazują histogramy najczęstszych *N-gramów*. Można zauważyć że najczęściej występującymi słowami są słowa należące do grupy słów nie wnoszących znaczenia (ang. *stop words*), np.: słowa popularne, spójniki, przedimki, jednak często występujące słowa to także wnoszące dużo znaczenia do wypowiedzi takie jak *love*, *like*, *good*, *hate*.



Rysunek 3.4. Rozkład wystąpień najczęstszych 1-gramów (wyrazów) w danych z EmoContext.



Rysunek 3.5. Rozkład wystąpień najczęstszych 2-gramów w danych z EmoContext.



Rysunek 3.6. Rozkład wystąpień najczęstszych 3-gramów w danych z EmoContext.

Rozdział 4

Przetwarzanie danych

Rozdział 5

Budowa modeli

TODO: użyj poniższych cytowań

[4] ULMFIT

[2] BERT

[1] GLOVE

Rozdział 6

Ewaluacja modeli

Rozdział 7

Podsumowanie

Zakończenie pracy zwane również Uwagami końcowymi lub Podsumowaniem powinno zawierać ustosunkowanie się autora do zadań wskazanych we wstępie do pracy, a w szczególności do celu i zakresu pracy oraz porównanie ich z faktycznymi wynikami pracy. Podejście takie umożliwia jasne określenie stopnia realizacji założonych celów oraz zwrócenie uwagi na wyniki osiągnięte przez autora w ramach jego samodzielnej pracy.

Integralną częścią pracy są również dodatki, aneksy i załączniki zawierające stworzone w ramach pracy programy, aplikacje i projekty.

Literatura

- [1] Robin Brochier, Adrien Guille, and Julien Velcin. Global vectors for node representations, 2019.
- [2] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding, 2018.
- [3] Paul Ekman. Facial expression and emotion, 1993.
- [4] Jeremy Howard and Sebastian Ruder. Universal language model fine-tuning for text classification, 2018.
- [5] Robert Plutchik. A psychoevolutionary theory of emotions, 1982.
- [6] Soujanya Poria, Navonil Majumder, Rada Mihalcea, and Eduard Hovy. Emotion recognition in conversation: Research challenges, datasets, and recent advances, 2019.
- [7] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2017.
- [8] Peixiang Zhong, Di Wang, and Chunyan Miao. Knowledge-enriched transformer for emotion detection in textual conversations, 2019.



© 2020 inż. Jakub Zdanowski

Instytut Informatyki, Wydział Informatyki i Telekomunikacji
Politechnika Poznańska

Skład przy użyciu systemu \LaTeX na platformie Overleaf.